

АНАЛИТИЧЕСКИЙ ОТЧЁТ

по результатам машинного обучения на RDKit-дескрипторах

Регрессия и классификация для IC50, CC50 и SI

Выполнено в рамках курсовой работы по машинному обучению

Объект исследования — набор молекулярных RDKit-дескрипторов и три целевые переменные: IC50, CC50 и SI. **Цель работы** — провести разведочный анализ данных (EDA), выполнить preprocessing, построить и сравнить модели регрессии и классификации, а также интерпретировать полученные результаты.

В работе решены задачи регрессии для IC50, CC50 и SI, а также четыре задачи бинарной классификации: IC50 выше медианы, CC50 выше медианы, SI выше медианы и $SI > 8$. Для регрессии использовались метрики RMSE, MAE и R2 на логарифмированной и исходной шкалах. Для классификации применялись accuracy, balanced accuracy, precision, recall, F1, ROC_AUC и PR_AUC.

ВВЕДЕНИЕ

Молекулярные дескрипторы позволяют формализовать структурные и физико-химические свойства соединений и использовать их в задачах прогнозирования биологической активности и токсичности. В данной работе анализировались три целевые переменные. IC50 (полумаксимальная ингибирующая концентрация) характеризует активность соединения как ингибитора — чем ниже значение, тем активнее вещество. CC50 (цитотоксическая концентрация 50 %) характеризует безопасность соединения для клеток. SI (индекс селективности) отражает избирательность и рассчитывается как $SI = CC50 / IC50$.

Практическая значимость работы заключается в сравнении разных семейств моделей машинного обучения и выявлении задач, в которых RDKit-дескрипторы дают наиболее устойчивое предсказание. Дополнительно оцениваются ограничения моделей: правые хвосты распределений, мультиколлинеарность признаков, переобучение tree-based алгоритмов и чувствительность метрик к дисбалансу классов.

ДАННЫЕ И РЕЗУЛЬТАТЫ EDA

Исходный датасет содержал 1001 строку и 213 столбцов: 3 целевые переменные и 210 молекулярных дескрипторов. После удаления строк с пропусками (3 строки, 0,3 %) и дубликатов (32 строки, 3,2 %) итоговая выборка составила 966 наблюдений. На этапе EDA выявлены сильная правосторонняя асимметрия распределений и выраженная мультиколлинеарность части дескрипторов.

Таблица 1 — Описательные статистики целевых переменных

Переменная	Среднее	Медиана	Max	Асимметрия	Asym. log1p	Примечание
IC50, mM	218,98	45,22	4128,53	3,80	-0,02	Сильный правый хвост
CC50, mM	583,89	422,16	4538,98	2,01	-0,94	Умеренная асимметрия
SI	98,56	3,91	15620,6	17,67	1,14	Экстремальный хвост

Таблица 2 — Баланс классов для задач классификации

Задача	Классы 0 / 1	Доля класса 1	Примечание
IC50 > median (46,0 mM)	483 / 483	50,0 %	Сбалансирована
CC50 > median (408,8 mM)	484 / 482	49,9 %	Практически сбалансирована
SI > median (3,91)	483 / 483	50,0 %	Сбалансирована
SI > 8	624 / 342	35,4 %	Умеренный дисбаланс; основная метрика — PR_AUC

PREPROCESSING И ОТБОР ПРИЗНАКОВ

Для предотвращения утечки данных из признакового пространства исключались все целевые переменные. Это особенно важно для SI, являющегося производной величиной CC50 / IC50. Линейные и tree-based модели обучались на разных наборах признаков с учётом специфики алгоритмов.

Таблица 3 — Этапы preprocessing и размерность признакового пространства

Этап	Признаков	Описание
Исходные признаки	210	Все RDKit-дескрипторы после очистки строк
После удаления константных	192	Удалено 18 признаков (VarianceThreshold)
X_tree (tree-based модели)	145	Удалены высококоррелированные пары ($ r \geq 0,90$)
X_linear (линейные модели)	97	Дополнительная VIF-редукция ($VIF > 10$)

Такое разделение снизило влияние мультиколлинеарности на линейные модели и позволило сохранить больше информации для алгоритмов, устойчивых к коррелированным признакам.

В качестве baseline рассматривались линейные модели, SVM, ансамбли деревьев решений и бустинговые алгоритмы: LinearRegression, Ridge, Lasso, ElasticNet, HuberRegressor, SVR/SVC, RandomForest, ExtraTrees, GradientBoosting, HistGradientBoosting, XGBoost, LightGBM, AdaBoost и Dummy-модели. Для подбора гиперпараметров применялся RandomizedSearchCV с кросс-валидацией.

РЕГРЕССИОННОЕ МОДЕЛИРОВАНИЕ

Для всех трёх регрессионных задач модели обучались на логарифмированной целевой переменной ($\log_{10}$). Для IC50 и CC50 финальная модель выбиралась по качеству на исходной шкале (R^2_{original}), так как значения в мМ имеют практическую интерпретацию. Для SI основная оценка проводилась на $\log$ -шкале, поскольку исходная шкала нестабильна из-за экстремального правого хвоста. Применялась кросс-валидация (5 фолдов) на обучающей выборке и финальная оценка на тестовой (80 / 20).

Регрессия IC50

Сильная правосторонняя асимметрия IC50 ($\text{skewness} = 3,80$) делает $\log$ -преобразование обязательным. Все tree-based модели показали высокий overfit

gap (0,69-0,93). Тюнинг улучшил RMSE_log на 4-5 %, однако ухудшил R2_original у большинства tuned-моделей.

Таблица 4 — Результаты регрессии IC50 (лучшие модели)

Модель	CV log_RMSE	log_R ² test	orig_R ² test	Примечание
RandomForest	1,403	0,375	0,237	baseline
XGBoost	1,446	0,357	0,377	baseline — лучший R2_orig
GradientBoosting	1,455	0,370	0,282	baseline
RandomForest_tuned	1,398	—	0,195	tuned
XGBoost_tuned	1,399	—	0,271	tuned
GBM_tuned	1,401	—	0,207	tuned

Финальная модель: XGBoost baseline (R2_original = 0,377). Ошибки в хвосте: IC50 > 500 мМ дают MAE 718 мМ против 174 мМ по всей выборке (в 4,1 раза выше).

Регрессия CC50

Умеренная асимметрия CC50 (skewness = 2,01) - наиболее предсказуемая задача. Overfit gap у tree-based моделей ниже (0,48-0,60). SVR_rbf оказался способен конкурировать с tree-based моделями.

Таблица 5 — Результаты регрессии CC50 (лучшие модели)

Модель	CV log_RMSE	log_R ² test	orig_R ² test	Примечание
LightGBM	1,185	0,500	0,500	baseline
ExtraTrees	1,187	0,492	0,529	baseline — лучший R2_orig
GBM_tuned	1,168	—	0,498	tuned — лучший log
HistGBM_tuned	1,184	—	0,526	tuned
ExtraTrees_tuned	1,185	—	0,359	tuned — деградация R2_orig

Финальная модель: ExtraTrees baseline (R2_original = 0,529). Хвостовая ошибка: CC50 > 1000 мМ дают MAE 633 мМ против 246 мМ (в 2,6 раза выше).

Регрессия SI

SI является производной величиной ($SI = CC50 / IC50$) с экстремальной асимметрией (skewness = 17,96, max = 15620). Регрессия на исходной шкале нецелесообразна: все tree-based модели имеют отрицательный $R^2_{original}$. Основная оценка выполнялась по $RMSE_{log}$; при интерпретации дополнительно учитывалось поведение моделей на исходной шкале.

Таблица 6 — Результаты регрессии SI (лучшие модели)

Модель	CV log_RMSE	log_R ² test	orig_R ² test	Примечание
RandomForest	1,237	0,212	-0,373	baseline
LightGBM	1,254	0,203	-0,254	baseline
ExtraTrees_tuned	1,210	—	-0,366	tuned — лучший CV RMSE_log
GBM_tuned	1,221	—	-0,109	tuned — лучший R ² _original среди tuned

Финальная модель: GradientBoosting_tuned ($RMSE_{log} = 1,226$). Эта модель выбрана как компромиссная: она уступает ExtraTrees_tuned по CV $RMSE_{log}$, но показывает лучший баланс $R^2_{original}$ среди tuned-моделей. Хвостовая ошибка: $SI > 50$ дают MAE 215 против 36 (в 5,9 раза выше).

КЛАССИФИКАЦИОННОЕ МОДЕЛИРОВАНИЕ

Во всех задачах применялось стратифицированное разбиение (80 / 20) и StratifiedKFold (5 фолдов). Для задач по медиане основная метрика — ROC_AUC. Для $SI > 8$ (дисбаланс 35,4 %) основная метрика — PR_AUC.

Таблица 7 — Итоговые результаты классификационных моделей

Задача	Доля кл. 1	Финальная модель	Осн. метрика	F1	PR_AUC
IC50 > median	50,0 %	RF_tuned	ROC_AUC = 0,818	0,735	0,818

Задача	Доля кл. 1	Финальная модель	Осн. метрика	F1	PR_AUC
CC50 > median	49,9 %	ET_tuned	ROC_AUC = 0,831	0,745	0,834
SI > median	50,0 %	ET_tuned	ROC_AUC = 0,754	0,659	0,752
SI > 8	35,4 %	ET_tuned	PR_AUC = 0,652	0,586	0,652

Таблица 8 — Матрицы ошибок финальных классификаторов

Задача	TN	FP	FN	TP	Интерпретация
IC50 > median	70	27	25	72	Ошибки симметричны
CC50 > median	71	26	24	73	Ошибки симметричны
SI > median	76	21	39	58	Recall кл. 1 = 0,598; модель чаще пропускает кл. 1
SI > 8	95	30	28	41	Почти симметрично; recall = 0,594

Наиболее сильные результаты получены для CC50 > median (ROC_AUC = 0,831). Для задачи SI > 8 важно не ограничиваться ассигасу: Dummy-модель достигает ассигасу = 0,644, тогда как PR_AUC = 0,652 реально показывает качество нахождения положительного класса.

ИНТЕРПРЕТАЦИЯ ПРИЗНАКОВ

Для всех финальных tree-based моделей использовалась встроенная feature_importances_. Важность признаков интерпретируется как модельная оценка вклада дескрипторов, а не как доказательство химической причинности.

Таблица 9 — Топ-3 признака финальных моделей

Задача	Топ-1	Топ-2	Топ-3
IC50 регрессия	NumSaturatedHeterocycles (0,089)	fr_Ar_OH (0,046)	VSA_EState8 (0,046)
CC50 регрессия	NHONCount (0,044)	fr_allylic_oxid (0,037)	fr_NH2 (0,036)
SI регрессия	FractionCSP3 (0,049)	BalabanJ (0,041)	VSA_EState4 (0,034)
IC50 классиф.	BCUT2D_MRLOW (0,037)	VSA_EState8 (0,031)	SlogP_VSA5 (0,024)
CC50 классиф.	fr_NH2 (0,070)	NumSaturatedHeterocycles (0,065)	BCUT2D_MRLOW (0,048)

Задача	Топ-1	Топ-2	Топ-3
SI>median классиф.	SMR_VSA4 (0,028)	SMR_VSA7 (0,025)	FractionCSP3 (0,023)
SI>8 классиф.	FractionCSP3 (0,049)	SMR_VSA7 (0,041)	NumAliphaticHeterocycles (0,038)

IC50 и CC50 имеют разные наборы наиболее важных признаков, что может отражать различие между активностью и цитотоксичностью. Однако `feature_importances_` является модельной оценкой и не доказывает химическую причинность. SI-задачи выделяют FractionCSP3 и SMR-дескрипторы, связанные с насыщенностью и физико-химическими свойствами молекул.

АНАЛИЗ РЕЗУЛЬТАТОВ

RDKit-дескрипторы содержат устойчивый предиктивный сигнал для всех задач. Лучше всего моделируется CC50 ($R^2_{\text{original}} = 0,529$; ROC_AUC = 0,831). IC50 предсказывается умеренно ($R^2_{\text{original}} = 0,377$; ROC_AUC = 0,818). SI является наиболее сложной целью ввиду производного характера и экстремального правого хвоста.

Tree-based модели стабильно превосходят линейные по качеству, но демонстрируют значительный overfit gap при малой выборке (772 наблюдения в train). В ряде задач логистическая регрессия и SVC оказываются конкурентоспособными.

Тюнинг по RMSE_log ухудшил R^2_{original} у большинства регрессионных моделей, поэтому для дальнейшей работы необходима мультиметрика. ExtraTrees_tuned в задаче CC50 деградировал с 0,529 до 0,359 по R^2_{original} . SVC_rbf показал наилучший PR_AUC в задаче SI > median (0,771), что указывает на конкурентоспособность SVM-подхода для части классификационных задач.

ОГРАНИЧЕНИЯ ИССЛЕДОВАНИЯ

К основным ограничениям работы относятся небольшой размер выборки после очистки (966 наблюдений), выраженные правые хвосты целевых переменных, сильная мультиколлинеарность исходных RDKit-дескрипторов и риск переобучения tree-based моделей. Дополнительно следует учитывать отсутствие внешней валидационной выборки: все выводы основаны на внутреннем train/test-разбиении и кросс-валидации.

Интерпретация признаков выполнена по встроенной `feature_importances_` у tree-based моделей. Поэтому полученные важности следует рассматривать как модельную оценку вклада дескрипторов, а не как доказательство химической причинности. Для предметной химической интерпретации требуется отдельная экспертная проверка.

ЗАКЛЮЧЕНИЕ

В работе выполнен полный цикл ML-анализа: EDA, preprocessing, отбор признаков, построение регрессионных и классификационных моделей, подбор гиперпараметров, диагностика ошибок и интерпретация признаков. Наиболее успешные результаты получены для CC50. Для IC50 качество умеренное, для SI - ограничено сложностью целевой переменной.

Для дальнейшего улучшения качества рекомендуется:

- 1) расширить обучающую выборку до 2000–3000 соединений;
- 2) добавить молекулярные fingerprints (ECFP4, Morgan) как дополнительные признаки;
- 3) использовать `R2_original` как вторичную метрику при `RandomizedSearchCV`;
- 4) для задачи SI > 8 выполнить подбор порога классификации (0,35–0,40) для снижения FN;
- 5) рассмотреть предсказание SI через отдельные модели IC50 и CC50.